

PREDICȚIA PRODUCTIVITĂȚII STUDENȚILOR
Documentație proiect de învățare
Machine Learning

Student: Bogdana-Nelia-Oana Tinc

2026

Cuprins

1	Introducere	2
1.1	Context	2
1.2	Motivație	2
1.3	Scopul proiectului	2
2	Descrierea datelor și a proiectului	3
2.1	Setul de date	3
2.2	Context educațional	4
2.3	Definirea problemei	4
3	State-of-the-Art	5
3.1	Fundamente teoretice ale algoritmilor utilizați	5
3.1.1	Regresia liniară / Linear regression	5
3.1.2	Arbore de decizie / Decision Tree	5
3.1.3	Random Forest	5
3.1.4	Gradient Boosting	5
4	Implementarea	6
4.1	Încărcarea, explorarea și curățarea datelor	6
4.1.1	Curățarea datelor	7
4.1.2	Feature Engineering	7
4.1.3	Selecția caracteristicilor	7
4.2	Algoritmii utilizați	8
4.3	Împărțirea datelor - antrenare, testare, validare	8
4.4	Optimizarea parametrilor	8
5	Testare și validare	9
5.1	Metrici de evaluare	9
5.2	Comparație între modele	9
6	Rezultate	10
6.1	Performanța modelului final	10
6.2	Erori	10
6.3	Explicabilitatea modelului	10
6.3.1	Importanța caracteristicilor	10
6.3.2	Analiza SHAP	11
7	Concluzii	12

1. Introducere

1.1. Context

În mediul academic, iese în evidență tot mai des lipsa de interes a studenților față de activitățile educaționale. O mulțime de distrageri apar în calea acestora, care le pun stăpânire pe timpul prețios pe care l-ar putea folosi în alte domenii, unde pot aduce plus valoare. Rețelele de socializare, orele de somn, prezența la cursuri sau orele petrecute în fața calculatoarelor sunt factori care influențează productivitatea unui student, atât pe plan academic, cât și în viața personală.

1.2. Motivație

Această temă a fost aleasă, deoarece gestionarea timpului și eficientizarea procesului de învățare constituie provocări majore pentru studenți, fiind considerată un bun prilej pentru aplicarea unui studiu, folosind tehnici de Machine Learning. Se dorește optimizarea abordării și organizării timpului liber și a sarcinilor de lucru, astfel s-a implementat un proiect care să automatizeze acest proces.

1.3. Scopul proiectului

Proiectul de față are rolul de a analiza activitățile pe care un student le întreprinde într-o zi și de a oferi o predicție a reușitei sale în ceea ce privește productivitatea. În funcție de rezultatele valoroase obținute și de tiparele identificare prin tehnici de Machine Learning, persoana analizată poate să își modifice deciziile de viață și să își îmbunătățească productivitatea, pentru a avea mai multe șanse de reușită.

2. Descrierea datelor și a proiectului

2.1. Setul de date

Studiul utilizează un set de date dedicat productivității studenților, preluat de pe platforma Kagle: <https://www.kaggle.com/datasets/sehaj1104/student-productivity-and-digital-distraction-dataset>.

Acesta conține 20000 de înregistrări, fiecare reprezentând un set de informații despre un student. Conform descrierii oferite pe site, acest set de date este *proiectat* pentru a ajuta la analiza influenței ce o au distragerile digitale și alte activități cotidiene asupra productivității unui student. Setul de date conține informații despre următoarele aspecte:

- study hours per day (timpul pe care un student îl petrece învățând)
- sleep hours (numărul de ore dormite pe zi)
- phone usage hours (timpul petrecut pe telefon)
- social media usage (timpul petrecut pe rețelele de socializare)
- YouTube usage (orele petrecute vizionând videoclipuri pe YouTube)
- gaming hours (timpul petrecut jucând jocuri video)
- stress level (nivelul de stres)
- focus score (scorul atenției)
- attendance percentage (prezența la cursuri)
- exercise minutes (minutele de antrenament fizic)
- coffee intake (câtă cafea consumă într-o zi)
- assignments completed (numărul de teme reolvate de student)
- final grade (nota finală obținută)
- productivity score (variabila target, scorul care se dorește aflat în urma aplicării tehnicilor de Machine Learning)

Deși aceste atribute sunt în număr mare, în urma analizelor efectuate asupra setului de date, s-a dovedit că doar puține dintre acestea au un cuvânt de spus în rezultatul predicției.

2.2. Context educațional

Modelarea predictivă a randamentului academic și a productivității zilnice a studenților constituie un subiect central în cercetările educaționale. Conform studiilor din domeniu, productivitatea nu este o constantă, ci o variabilă dinamică influențată masiv de factorii de mediu și de obiceiurile cotidiene[7].

O atenție deosebită în literatura de specialitate este acordată „distragerii digitale”. Cercetările conduse de Rosen et al.[8] arată că multitasking-ul forțat de fluxul continuu de notificări de pe rețelele de socializare cauzează o degradare a capacității de concentrare intensă („deep work”). Studenții alternează, astfel, sarcinile de studiu la intervale foarte scurte. Acest fenomen, numit „task-switching” crește încărcarea cognitivă și reduce capacitatea de asimilare a cunoștințelor.

Junco și Cotten[9] au stabilit o corelație negativă între timpul petrecut pe platformele de divertisment în timpul orelor de studiu și performanța academică finală.

În schimb, dacă tehnologia este utilizată în mod controlat, iar comportamentul studentului este reglat prin tehnici de gestionare a timpului, s-a demonstrat că acestea vor avea un impact pozitiv asupra productivității[10, 11].

2.3. Definirea problemei

Problema de rezolvat este formulată ca o sarcină de regresie, care constă în: predicția scorului de productivitate al unui student.

Astfel, scopul final este construirea unui model capabil să anticipeze randamentul unui student pe baza comportamentului său zilnic.

Pentru realizarea acestei sarcini s-a folosit limbajul Python, alături de biblioteci fundamentale pentru Machine Learning:

- Pandas - utilizată pentru încărcarea, curățarea și transformarea structurală a celor 20000 de înregistrări
- Matplotlib și Seaborn - esențiale pentru componenta de vizualizare, pentru generarea matricelor de corelație și a graficelor analitice.
- Scikit-learn - cu ajutorul acesteia s-a realizat împărțirea datelor, optimizarea hiperparametrilor și antrenarea algoritmilor
- SHAP - asigură explicabilitatea direcțională a predicțiilor modelului final

3. State-of-the-Art

3.1. Fundamente teoretice ale algoritmilor utilizați

În cadrul acestui proiect au fost testate și comparate mai multe modele de complexități diferite:

3.1.1. Regresia liniară / Linear regression

Regresia liniară este un algoritm parametric utilizat pentru a modela relația dintre o variabilă dependentă continuă (productivity_score) și un set de variabile independente[1].

3.1.2. Arbore de decizie / Decision Tree

Arborii de decizie sunt modele non-parametrice care realizează segmentarea spațiului caracteristicilor în regiuni distincte prin aplicarea unor reguli de decizie succesive [2].

La fiecare nod, algoritmul selectează caracteristica și pragul de splitare care maximizează puritatea nodurilor rezultate. În această problemă de regresie, criteriul de selecție este reducerea varianței sau minimul erorii pătratice medii, MSE.

Predicția finală într-o frunză reprezintă media valorilor instanțelor din acea regiune. Avantajul principal este interpretabilitatea ridicată, însă algoritmul este predispus la supraînvățare (overfitting).

3.1.3. Random Forest

Pentru a corecta tendința de supraînvățare a unui singur arbore, Leo Breiman [3] a introdus algoritmul Random Forest. Acesta este un model de tip ansamblu care utilizează tehnica Bagging (Bootstrap Aggregating).

Algoritmul antrenează o mulțime de arbori de decizie în paralel pe subseturi diferite de date extrase prin eșantionare cu înlocuire. La fiecare split în interiorul arborilor, se selectează un subset aleatoriu de caracteristici. Predicția ansamblului este obținută prin medierea rezultatelor tuturor arborilor.

Această tehnică reduce varianța modelului fără a crește bias-ul, oferind o robustețe ridicată la zgomotul din datele comportamentale.

3.1.4. Gradient Boosting

Spre deosebire de Random Forest unde arborii sunt independenți, Gradient Boosting construiește arborii în mod secvențial, utilizând principiul de *Boosting* [4]. Fiecare arbore nou adăugat în ansamblu este antrenat pentru a prezice și corecta erorile (reziduurile) lăsate de combinația arborilor precedenți.

Gradient Boosting excelează în capturarea relațiilor complexe dintre variabile, fiind adesea cel mai performant algoritm pe date structurate.

4. Implementarea

4.1. Încărcarea, explorarea și curățarea datelor

Procesul de implementare a început cu încărcarea setului de date în formatul .csv, utilizând biblioteca `pandas`. Acesta cuprinde 20000 de înregistrări, fiecare reprezentând atributele unui student.

Analiza exploratorie inițială, EDA, a evidențiat absența valorilor lipsă, însă a semnalat necesitatea unor transformări structurale asupra datelor brute.

În imaginea următoare este reprezentată matricea de corelație pentru dataset-ul inițial, fără modificări.




Figura 4.1 Matricea de corelație inițială

4.1.1. Curățarea datelor

Variabila categorială **gender** a fost normalizată și transformată în variabile numerice de tip *One-Hot Encoding*, creându-se coloanele binare **is_male**, **is_female** și **is_other**. Ulterior, coloana originală de tip șir de caractere a fost eliminată.

Identificatorul unic **student_id** a fost eliminat, neavând putere predictivă.

Pentru a preveni erorile în algoritmi bazati pe arbori decizionali, variabilele stocate sub formă de intervale au fost convertite în valori numerice continue prin extragerea mijlocului intervalului respectiv.

4.1.2. Feature Engineering

Pentru a surprinde mai bine comportamentul studenților, au fost create trei caracteristici noi:

1. **total_screen_time** = **gaming_hours** + **phone_usage_hours**, adică suma orelor de gaming și a celor de utilizare a telefonului, reprezentând timpul total alocat activităților digitale non-academice
2. **study_efficiency**: raportul dintre orele de studiu și timpul total pe ecran:

$$\text{study_efficiency} = \frac{\text{study_hours_per_day}}{\text{total_screen_time} + 1}$$

3. **lifestyle_quality** =
$$= 0.6 * \text{sleep_hours} + 0.4 * \text{exercise_minutes}$$

relație liniară între cele două caracteristici

4.1.3. Selecția caracteristicilor

În prima fază de antrenare a unui model Random Forest, s-a observat că metricile obțineau un coeficient de determinare R^2 aproape de 1.0, sugerând un fenomen de data leakage sau redundanță severă. Analiza matricei de corelație a arătat următoarele aspecte:

1. Variabila **lifestyle_quality** prezenta o corelație perfectă cu **exercise_minutes** dar una neimportantă cu variabila țintă, deci a fost eliminată.
2. Noua caracteristică **study_efficiency** genera scoruri artificial de mari, motiv pentru care a fost scoasă din setul final de predictorii pentru a asigura robustețea modelului.
3. Multe caracteristici aveau corelație nulă cu variabila target, deci au fost eliminate treptat.

Pentru stabilirea setului optim de caracteristici, s-a rulat un experiment ce testează praguri de corelație absolută de la 0 la 0.3. Prin eliminarea coloanelor cu o corelație sub pragul de 0.1, modelul își păstrează performanța, dar un prag de 0.2 duce la o prăbușire a scorului R^2 .

Așadar, s-a selectat un prag de 0.1, reținându-se doar șapte caracteristici esențiale pentru modelarea variabilei țintă **productivity_score**:

1. **study_hours_per_day**
2. **focus_score**
3. **sleep_hours**
4. **phone_usage_hours**
5. **total_screen_time**
6. **stress_level**
7. **attendance_percentage**

4.2. Algoritmii utilizați

În cadrul experimentelor au fost evaluați comparativ patru algoritmi de bază și două tehnici avansate de ansamblu:

- **Regresia liniară** (cu Ridge) - utilizată ca model de referință pentru a penaliza o posibilă legătură strânsă între date
- **Arborele de decizie** - model fără parametri, capabil să găsească relații non-liniare, dar predispus al overfitting
- **Random Forest regressor** - mediază predicțiile mai multor arbori independenți pentru a reduce varianța
- **Gradient Boosting regressor** - algoritm de tip boosting care construiește arbori secvențial, corectând la fiecare pas erorile reziduale ale arborilor anteriori
- **Voting Regressor** - model ansamblu care mediază liniar predicțiile varietatelor cele mai bune ale modelelor Ridge, Random Forest și Gradient Boosting
- **Stacking Regressor** - tehnică avansată în care modelele de bază (Random Forest, Gradient Boosting și Decision Tree) generează predicții ce servesc drept caracteristici de intrare pentru un model final (Ridge Regression)

4.3. Împărțirea datelor - antrenare, testare, validare

Setul de date a fost divizat în eșantioane independente. S-a folosit o strategie ce combină împărțirea statică cu Cross-Validation.

Folosind funcția `train_test_split` din biblioteca `scikit-learn`, datele au fost împărțite în:

- setul de antrenare - 80% - utilizat pentru ajustarea coeficienților și învățarea regulilor de decizie de către algoritmi
- setul de testare - 20% - păstrat izolat în timpul instruirii, fiind utilizat doar pentru evaluarea finală a capacității de generalizare pe date noi.

4.4. Optimizarea parametrilor

Reglarea modelelor s-a realizat prin tehnica GridSearch, evaluând toate combinațiile posibile de hiperparametri dintr-un spațiu predefinit.

Pentru garantarea stabilității rezultatelor și prevenirea overfitting-ului, fiecare configurație a fost validată prin 5-Fold Cross-Validation, având obiectivul maximizării coeficientului de determinare.

- Optimizare **Ridge regression**: s-a ajustat parametrul alpha de regularizare
- Optimizare **Decision tree**: calibrarea adâncimii maxime, a numărului de eșantioane pentru divizarea nodurilor și a frunzelor și a selecției caracteristicilor
- Optimizare **Random forest**: s-a optimizat numărul total de arbori independenți, adâncimea maximă, nodurile, frunzele și subgrupul de caracteristici
- Optimizare **Gradient boosting**: calibrarea ritmului de contracție, a numărului de etape iterative, a adâncimii arborilor slabi și a proporției de date eșantionate, pentru ansamblul bazat pe învățarea secvențială

În urma analizării comparative a tuturor modelelor încercate, algoritmul ales este **Gradient Boosting Tuned**. Selecția este bazată pe obținerea unui echilibru optim între acuratețea predictivă foarte ridicată și interpretabilitatea modelului. Aceste detalii vor fi descrise mai pe larg în capitolul următor, *Rezultate*.

5. Testare și validare

5.1. Metrice de evaluare

Pentru a măsura performanța modelelor de regresie și pentru a evalua erorile de predicție pe setul de testare, au fost utilizate trei metrice de evaluare:

1. **MAE** (eroarea medie absolută) - calculează media aritmetică a magnitudinii erorilor în valoare absolută, oferind o vedere asupra abaterii medii a predicțiilor față de valorile reale ale scorului de productivitate.
2. **RMSE** (rădăcina erorii pătratice medii) - spre deosebire de MAE, penalizează mai sever erorile mari de predicție, prin ridicarea la pătrat a diferențelor înainte de mediere.
3. R^2 (coeficientul de determinare) - măsoară proporția din varianța variabilei țintă

5.2. Comparatie între modele

Performanțele obținute de algoritmi optimizați, după evaluarea pe setul de testare izolat, sunt centralizate în ordinea descrescătoare a coeficientului R^2 , în Tabelul 5.1:

Nr.	Model	MAE	RMSE	R^2
1.	Ridge Regression	0.002484	0.002874	1.000000
2.	Stacking Regressor	0.670681	0.834216	0.997298
3.	Gradient Boosting Tuned	0.678367	0.849237	0.997200
4.	Voting Regressor	0.752615	0.958242	0.996435
5.	Random Forest Tuned	1.878647	2.396098	0.977712
6.	Decision Tree Tuned	3.517723	4.379823	0.925530

Tabela 5.1 Rezultatele comparative ale modelelor

- Ridge Regression înregistrează metrice ideale ($R^2 = 1.0$), ceea ce confirmă prezența unei corelații liniare generate de structura setului de date.
- Modelul Decision Tree Tuned a obținut cea mai slabă performanță, dar trecerea la tehnici de ansamblu a corectat această varianță.
- Cele mai bune rezultate au fost atinse de **Stacking Regressor** și **Gradient Boosting Tuned**.

Modelul final selectat este **Gradient Boosting Tuned**, deoarece asigură atât o performanță ridicată, cât și echilibru între acuratețe și interpretabilitate.

6. Rezultate

6.1. Performanța modelului final

În urma etapei de evaluare comparativă, modelul **Gradient Boosting Tuned** a fost selectat ca model final, datorită capacității sale de a modela interacțiunile dintre indicatorii comportamentali ai studenților.

Conform Tabelului 5.1, performanța sa pe setul de date de testare e indicată de coeficientul de determinare $R^2 = 0.9972$. Această valoare spune că modelul poate explica peste 99.7% din variabilitatea (`productivity_score`), folosind cele șapte caracteristici rămase.

Valoarea parametrului $MAE = 0.6783$ indică faptul că predicția oferită de model diferă cu mai puțin (în termeni probabilistici) de nivelul real al productivității studentului.

Indicele redus $RMSE = 0.8492$ confirmă absența erorilor majore sau a fluctuațiilor mari de predicție.

Astfel, este demonstrată o consistență ridicată a algoritmului selectat pe întreg eșantionul de test.

6.2. Erori

Deși modelul Gradient Boosting Tuned prezintă o acuratețe remarcabilă, totuși, analiza reziduurilor este esențială pentru înțelegerea limitărilor sale.

- Natura reziduurilor - MAE de ~ 0.68 puncte provine din mici aproximații pe care funcțiile de pierdere ale arborilor de decizie le fac în frunze, unde variațiile dintre studenții cu profile similare sunt mediate.
- Indicele $RMSE$, fiind apropiat de cel MAE , sugerează că erorile sunt distribuite omogen, fără outliers, care să producă eșecuri majore în predicție.
- Sursa potențială a varianței - diferența reziduală ar putea fi influențată de factori psihologici sau de mediu, pe care un set de date sintetic nu îi poate cuantifica în totalitate.

6.3. Explicabilitatea modelului

S-au utilizat două tehnici complementare de interpretare: importanța caracteristicilor și analiza SHAP.

6.3.1. Importanța caracteristicilor

Calculată prin intermediul algoritmului Gradient Boosting, aceasta măsoară reducerea totală a criteriului de impuritate adusă de fiecare variabilă în structura arborilor. Rezultatele de pot observa în Figura 6.1 și relevă următoarele aspecte:

- Variabila `study_hours_per_day` deține cea mai mare pondere și influență asupra variabilei țintă
- Restul caracteristicilor din setul redus de date au o importanță mai scăzută, adică modelul se bazează majoritar pe orele de studiu pentru a genera predicția.




Figura 6.1 Feature importance

6.3.2. Analiza SHAP

Graficul de rezumat SHAP aduce o perspectivă direcțională asupra impactului fiecărei variabile la nivel de student. Acesta este ilustrat în Figura 6.2:

- **Efectul orelor de studiu** - Valorile mari ale acestei caracteristici în partea dreaptă a axei SHAP demonstrează o relație de proporționalitate directă, astfel, cu cât un student învață mai mult, cu atât va crește și scorul de productivitate al acestuia.
- **Efectul utilizării telefonului** - Gruparea punctelor roșii în partea stângă a axei reprezintă o relație de proporționalitate inversă. Un timp îndelungat petrecut pe dispozitivele mobile acționează ca un factor perturbator major, scăzând puternic nivelul de productivitate prezis de model.




Figura 6.2 Analiza SHAP

7. Concluzii

Acest proiect a permis dezvoltarea și evaluarea unui sistem predictiv pentru analiza productivității studenților în raport cu factorii de distragere digitală.

În urma parcurgerii tuturor etapelor, începând cu analiza exploratorie a datelor, până la interpretarea modelului final, au fost extrase următoarele concluzii și cunoștințe esențiale:

- s-a constatat importanța calității datelor brute. Utilizarea unui set de date sintetic, deși oferă un mediu controlat și curat, tinde să simplifice artificial realitatea. Relațiile matematice stricte dintre date pot conduce la rezultate ideale, ce nu reflectă fidel comportamentul uman
- Obținerea unei acurateți ridicate nu este suficientă. Este necesară abilitatea de a explica vizual de ce un model oferă o anumită predicție.
- Cea mai mare limitare a proiectului este fundamentare algoritmilor pe un set de date generat artificial, deoarece se elimină din start zgomotul specific realității.
- Principala îmbunătățire vizată constă în proiectarea și distribuirea unui chestionar sociologic în rândul studenților. Datele colectate anonim pot fi folosite pentru antrenarea și validarea modelului într-un scenariu autentic.
- O perspectivă pe termen lung e reprezentată de integrarea modelului Gradien Boosting Tuned într-o aplicație web sau mobilă, care să fie la îndemâna studenților pentru a-i ajuta în trăirea la potențialul maxim.

Bibliografie

- [1] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*, Springer Science & Business Media, 2013.
- [2] J. R. Quinlan, *Induction of decision trees*, Machine Learning, vol. 1, no. 1, pp. 81-106, 1986.
- [3] L. Breiman, *Random Forests*, Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.
- [4] J. H. Friedman, *Greedy function approximation: a gradient boosting machine*, Annals of Statistics, pp. 1189-1232, 2001.
- [5] J. Bergstra and Y. Bengio, *Random search for hyper-parameter optimization*, Journal of Machine Learning Research, vol. 13, pp. 281-305, 2012.
- [6] F. Pedregosa et al., *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [7] M. Rashid et al., *Predicting Student Performance Using Machine Learning: A Review*, International Journal of Advanced Computer Science and Applications, vol. 12, no. 5, 2021.
- [8] L. D. Rosen, K. Carrier, and N. A. Cheever, *Facebook and texting made me do it: Media-induced task-switching while studying*, Computers in Human Behavior, vol. 29, no. 3, pp. 948-958, 2013.
- [9] R. Junco and S. R. Cotten, *No A 4 U: The relationship between multitasking and academic performance*, Computers & Education, vol. 59, no. 2, pp. 505-514, 2012.
- [10] O. Lecuona, J. I. Greenwood, et al., *Focusing on the present: The role of mindfulness in regulating digital distractions*, Computers in Human Behavior, vol. 113, p. 106516, 2020.
- [11] A. Agrawal, *The Impact of Digital Distractions on Student Productivity: A Predictive Modeling Approach*, IEEE International Conference on Advanced Learning Technologies (ICALT), pp. 112-116, 2022.